Avaliação de respostas de questões subjetivas de exames passados da OAB por um modelo de IA

Aluno: Eduardo Henrique

Data de realização de teste: 07/04/2026

Código fonte: https://github.com/eduoududu/juridico

Etapas Realizadas:

- **Importação do conjunto de dados de perguntas da OAB:** o conjunto de dados de perguntas de provas passadas da OAB foi importado do GitHub, disponível publicamente no endereço web: https://github.com/maritaca-ai/oab-bench/blob/main/data/judge_prompts.jsonl.
- **Importação do dataset de linha guia:** o dataset de linha guia, contendo as respostas relacionadas às perguntas, foi importado do mesmo projeto do GitHub, pela URL: https://github.com/maritaca-ai/oab-bench/blob/main/data/oab_bench/reference_answer/guidelines.jsonl.
- **Adição de números às questões:** foram adicionados números às questões para facilitar a leitura humana, considerando que o contador em listas no Python inicia do zero.
- **Análise e classificação do nível de dificuldade:** foi realizada uma análise manual e interativa, com o auxílio de IA, para classificar o nível de dificuldade das questões, e essa informação foi incluída no conjunto de perguntas.
- **Interseção entre dataframes:** foi realizada uma interseção entre os dataframes de questões e de linha guia para reunir todas as informações relevantes em um único dataframe.
- **Seleção de subconjunto de questões:** por fim, um subconjunto das questões, especificamente da questão 31 à 40, foi retirado para análises mais focadas.
- **Organização em Notebooks Separados:** para otimização e organização, o arquivo responsável pela extração, limpeza e carga dos dados foi separado em um notebook à parte.
- **Processamento de Questões por IA:** outro notebook utilizou os dados do primeiro e percorreu todo o conjunto, submetendo as questões a diferentes modelos de IA.

- **Estruturação da Pergunta em Markdown:** a pergunta foi cuidadosamente estruturada em formato Markdown para maior detalhamento do conteúdo a ser enviado a uma IA via chave de API.
- **Conteúdo do Markdown:** o prompt Markdown incluiu os seguintes elementos: papel, categoria, contexto, dificuldade e instrução.
- **Observações sobre Questões Tipo 'Peça':** em análise manual dos dados, foi percebido que, do conjunto de 10 linhas, duas são peças (informação retirada do campo 'statement'). Nesses casos, o campo 'turns' (instrução) estava vazio, o que pode indicar que não se trata de uma questão tradicional. Mesmo assim, foram submetidas às IAs para observar o comportamento.
- **Modelos de IA Utilizados:** as questões foram enviadas a três modelos de IA: **llama-3.1-8b-instant**, **meta-llama/llama-4-scout-17b-16e-instruct** e **gemini-3.1-flash-lite-preview**. Esses modelos foram escolhidos por suas características e pela possibilidade de uso gratuito nesta atividade.
- **Métrica de Avaliação: BERTScore:** métrica quantitativa utilizada para avaliar a acurácia das respostas de cada IA, comparando-as com a linha guia.
- **Tentativa de Avaliação por Juiz Online (IA):** foi feita uma tentativa de utilizar um 'Juiz Online', uma quarta IA robusta, para avaliar as respostas. No entanto, as restrições de uso de IAs gratuitas impossibilitaram essa abordagem.
- **Relatório Comparativo Final:** ao final, foi gerado um relatório comparativo utilizando os resultados do BERTScore.

Resultados Encontrados:

Gráfico de Acurácia Geral

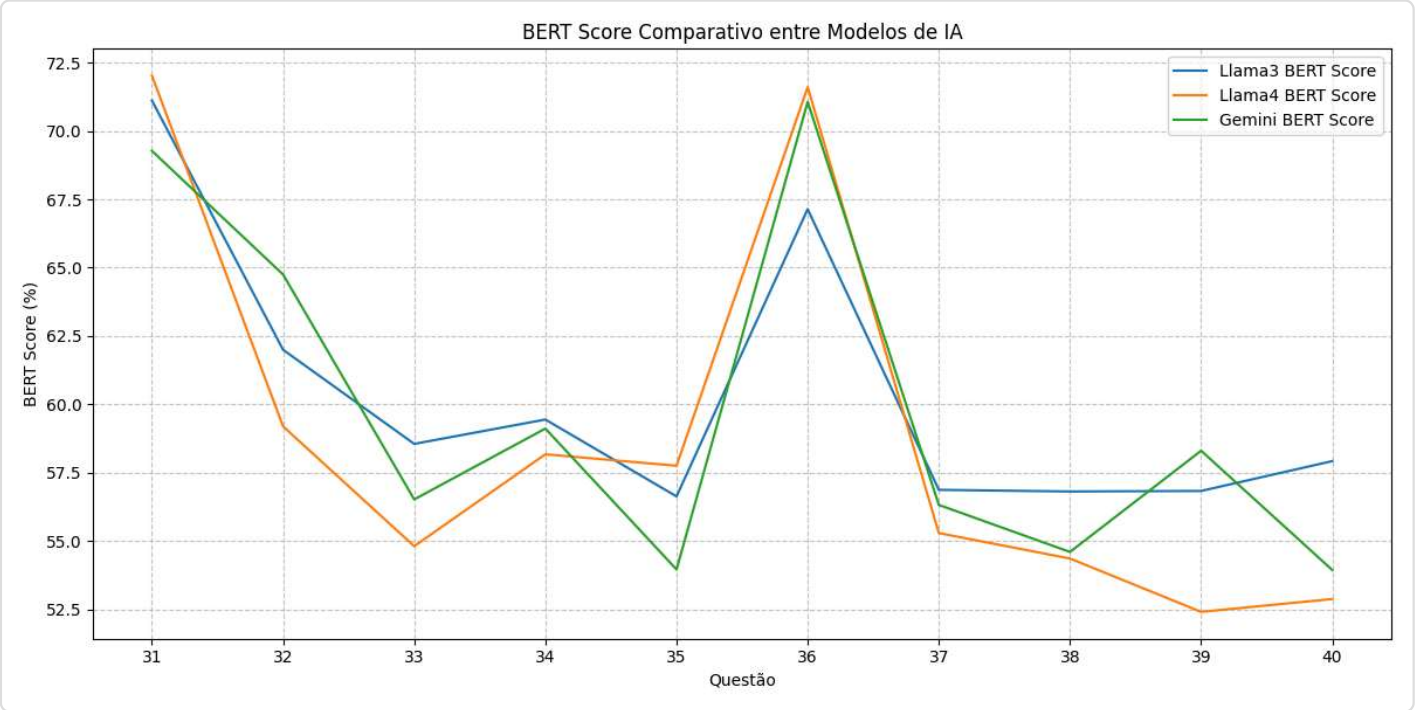

Pontuação das Respostas namétrica BERTScore

Questão	Dificuldade	Llama3 (%)	Llama4 (%)	Gemini (%)
31	Estagiário	71.11	72.02	69.27
32	Juiz	62.00	59.20	64.75
33	Juiz	58.56	54.82	56.53
34	Juiz	59.45	58.18	59.12
35	Juiz	56.64	57.76	53.97
36	Estagiário	67.14	71.60	71.06
37	Juiz	56.88	55.30	56.33
38	Juiz	56.82	54.37	54.61
39	Juiz	56.84	52.42	58.31
40	Juiz	57.93	52.89	53.95