Relatório Helena Carvalho Leal

Matrícula: 202611000223

1. Introdução

O presente trabalho investiga a capacidade de LLMs em resolver questões do Exame da Ordem dos Advogados do Brasil (OAB), um dos principais instrumentos de avaliação do conhecimento jurídico no país. A escolha desse benchmark se justifica por sua natureza estruturada, abrangência temática e exigência de raciocínio jurídico aplicado, que envolve desde a interpretação literal da lei até a análise de casos práticos complexos.

Foi desenvolvido um processo sistemático de curadoria dos datasets utilizados, contemplando tanto questões abertas quanto de múltipla escolha. Esse processo incluiu a classificação das questões segundo critérios bem definidos, como nível de dificuldade, área do Direito e fundamentação legal obrigatória, assegurando que a análise não fosse subjetiva, mas ancorada no ordenamento jurídico vigente.

Além disso, o trabalho propõe um pipeline de inferência e avaliação que combina métricas qualitativa, permitindo uma análise abrangente do desempenho dos modelos. Aspectos como fundamentação legal, estrutura formal e clareza de redação.

Dessa forma, este estudo contribui para a compreensão das potencialidades e limitações dos LLMs no contexto jurídico.

2. Metodologia de Curadoria

Esta seção detalha a curadoria dos datasets (**OAB-Bench** para questões abertas e **OAB Exams** para questões de múltipla escolha).

2.1. Taxonomia de Dificuldade

Para padronizar a análise entre os membros da equipe, estabelecemos quatro níveis hierárquicos de dificuldade, inspirados na progressão da carreira jurídica:

- **Nível 1 - Estagiário:** Questões de baixa complexidade, focadas na **literalidade da lei**.
- **Nível 2 - Analista:** Itens que exigem domínio de **ritos processuais, prazos** e normas procedimentais específicas.
- **Nível 3 - Juiz de Direito:** Questões baseadas em **casos práticos**, exigindo a capacidade de interpretar fatos e realizar a subsunção do fato à norma (aplicação do direito ao caso concreto).

- **Nível 4 - Ministro (STF/STJ):** O nível mais alto de exigência, envolvendo **controle de constitucionalidade, súmulas vinculantes** e interpretação de jurisprudência consolidada dos tribunais superiores.

2.2. Áreas de Especialidade

As 7 áreas principais definidas pela equipe foram: Administrativo, Civil, Constitucional, Trabalho, Empresarial, Penal e Tributário. Além desses rótulos base, o agente curador teve **liberdade técnica** para identificar e sugerir subáreas ou áreas quando o enunciado assim exigisse. Essa decisão estratégica visou:

2.3. Fundamentação Legal (Referência)

Um critério obrigatório da nossa curadoria foi a **exigência de fundamentação**. Nenhuma questão foi classificada sem a indicação precisa do dispositivo legal (Artigo de Lei, Código, Constituição ou Súmula) que serve de base para o gabarito. Isso assegurou que a classificação não fosse subjetiva, mas ancorada no ordenamento jurídico vigente.

2.4. Prompt da Curadoria (Questões Fechadas)

1. PERSONA

Você é um Professor Especialista em Direito e Consultor de Curadoria de Dados Jurídicos, com profundo conhecimento do Exame de Ordem da OAB e da jurisprudência dos tribunais superiores.

2. CONTEXTUALIZAÇÃO

Estamos realizando uma atividade de curadoria de um dataset de questões da OAB para treinar modelos de linguagem. Sua tarefa é classificar tecnicamente cada questão para que possamos entender o nível de exigência cognitiva e a área do Direito envolvida.

3. DEFINIÇÕES E CRITÉRIOS

Níveis de Dificuldade:

- Nível 1 Estagiário: Questões de aplicação direta da lei (literalidade).

- Nível 2 Analista: Questões que exigem conhecimento de ritos processuais ou prazos.

- Nível 3 Juiz de Direito: Questões que exigem interpretação de casos práticos e subsunção do fato à norma.

- Nível 4 Ministro (STF/STJ): Questões complexas envolvendo controle de constitucionalidade, súmulas vinculantes ou jurisprudência consolidada.

Áreas de Especialidade Permitidas:

[direito_administrativo, direito_civil, direito_constitucional, direito_do_trabalho, direito_empresarial, direito_penal, direito_tributario]

4. INSTRUÇÕES EXPLÍCITAS

1. Analise o enunciado e as alternativas fornecidas.

2. Identifique a área de especialidade dentro da lista permitida.

3. Determine o nível de dificuldade com base nos critérios acima.

4. Indique a referência legal exata (Artigo, Lei, Súmula) que fundamenta o gabarito.

5. Seja técnico e preciso. Se o gabarito for {item['answerKey']}, foque na explicação desta alternativa.

DADOS DA QUESTÃO:

ENUNCIADO: {item['question']}

ALTERNATIVAS: {alternativas}

GABARITO: {item['answerKey']}

5. FORMATO DE SAÍDA ESTRUTURADO

Responda obrigatoriamente no formato JSON:

{{

"area": "nome_da_area",

"dificuldade": "Nível X - Nome",

"referencia": "Art. X da Lei Y"

}}

2.5. Resultados da Curadoria (Questões Fechadas)

Após a execução do pipeline de curadoria obtivemos uma visão quantitativa do lote de 106 questões de múltipla escolha (IDs 425 a 530):

- **Nível 1 - Estagiário (29 questões):** Aproximadamente 27% do lote foca na literalidade da lei.
- **Nível 2 - Analista (32 questões):** Uma parcela significativa exige conhecimento procedimental e prazos.
- **Nível 3 - Juiz de Direito (32 questões):** Uma parcela significativa exige conhecimento acerca da aplicação do direito a casos práticos complexos.
- **Nível 4 - Ministro (13 questões):** O nível de maior complexidade representa a menor parcela.

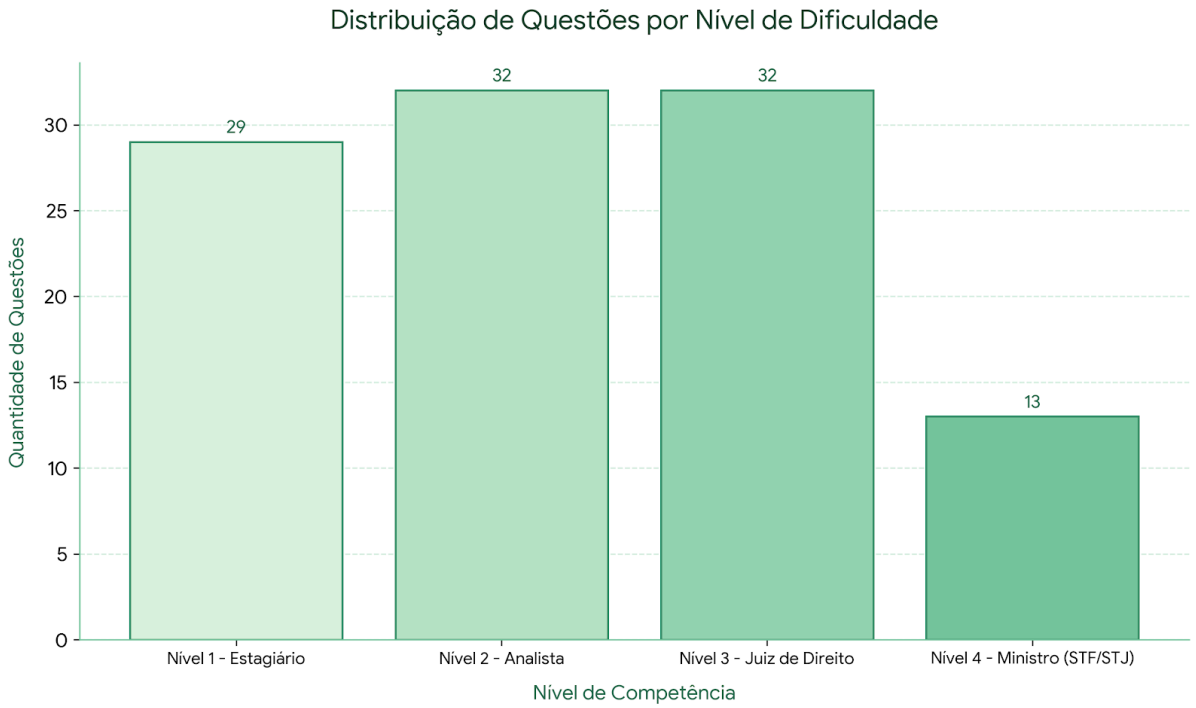

O gráfico abaixo apresenta a divisão das 106 questões por área jurídica. O **Direito Civil** é o tema central com 30 questões, seguido por **Penal (20)**, **Constitucional (17)** e **Trabalho (15)**. Áreas como **Administrativo** e **Tributário** têm presença moderada, enquanto o **Direito Empresarial** foi o menos cobrado (2 questões).

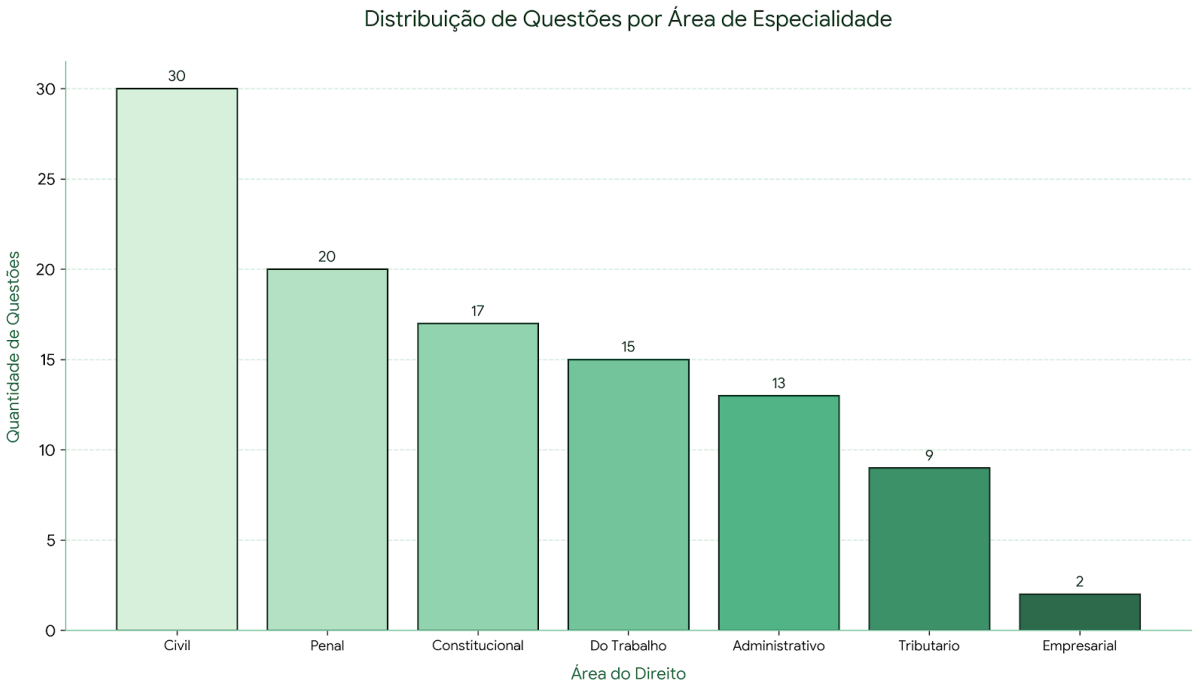

2.4. Prompt da Curadoria (Questões Abertas)

1. PERSONA

Você é um Professor Especialista em Direito e Consultor de Curadoria de Dados Jurídicos, com profundo conhecimento do Exame de Ordem da OAB e da prática processual nos tribunais.

2. CONTEXTUALIZAÇÃO

Estamos realizando a curadoria de um dataset de questões ABERTAS (Discursivas e Peças Profissionais) da OAB. Sua tarefa é classificar tecnicamente o enunciado para entender o nível de complexidade jurídica e a área envolvida.

3. DEFINIÇÕES E CRITÉRIOS

Níveis de Dificuldade:

- Nível 1 Estagiário: Questões discursivas de resposta direta na lei (literalidade).

- Nível 2 Analista: Exige conhecimento de ritos, prazos ou competência básica.

- Nível 3 Juiz de Direito: Casos práticos complexos que exigem subsunção do fato à norma e redação de teses jurídicas.
- Nível 4 Ministro (STF/STJ): Questões envolvendo controle de constitucionalidade, súmulas vinculantes ou peças processuais de alta complexidade.

Áreas de Especialidade Permitidas:
[direito_administrativo, direito_civil, direito_constitucional, direito_do_trabalho, direito_empresarial, direito_penal, direito_tributario]

4. INSTRUÇÕES EXPLÍCITAS
1. Analise o ENUNCIADO (caso fático) e as PERGUNTAS/COMANDOS fornecidos.
2. Identifique a área de especialidade dentro da lista permitida.
3. Determine o nível de dificuldade considerando a complexidade da peça ou das respostas exigidas.
4. Indique a referência legal principal (Artigo, Lei ou Súmula) necessária para fundamentar a solução do caso.
5. Diferencie se é uma "Questão Discursiva" ou "Peça Profissional" no campo de observação.

DADOS DA QUESTÃO:
ENUNCIADO: {statement}
PERGUNTAS/COMANDOS: {turns}

5. FORMATO DE SAÍDA ESTRUTURADO
Responda obrigatoriamente no formato JSON puro, sem markdown:
{{
"area": "nome_da_area",
"dificuldade": "Nível X - Nome",
"referencia_principal": "Art. X da Lei Y",
"tipo_questao": "Peça Profissional ou Discursiva"
}}

2.5. Resultados da Curadoria (Questões Abertas)

Este gráfico de barras mostra a complexidade técnica das questões usando a nossa escala de "Estagiário" a "Ministro". A maioria (7 questões) está no Nível 3 - Juiz de Direito, o que significa que o lote exige que a IA saiba aplicar a lei a problemas práticos complexos, e não apenas repetir textos legais.

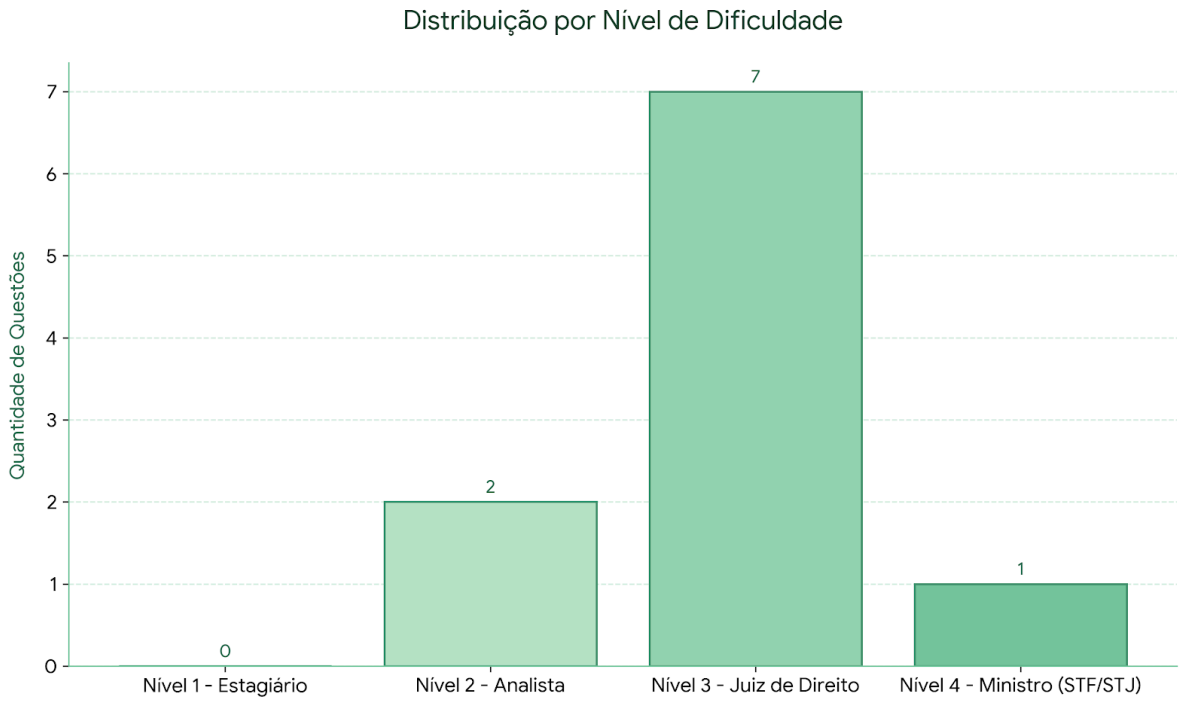

O gráfico abaixo apresenta quais ramos do Direito compõem o lote de 10 questões. O **Direito Civil** é o tema central, representando metade das questões, enquanto o restante se divide entre as áreas **Constitucional**, **Tributária** e **Administrativa**.

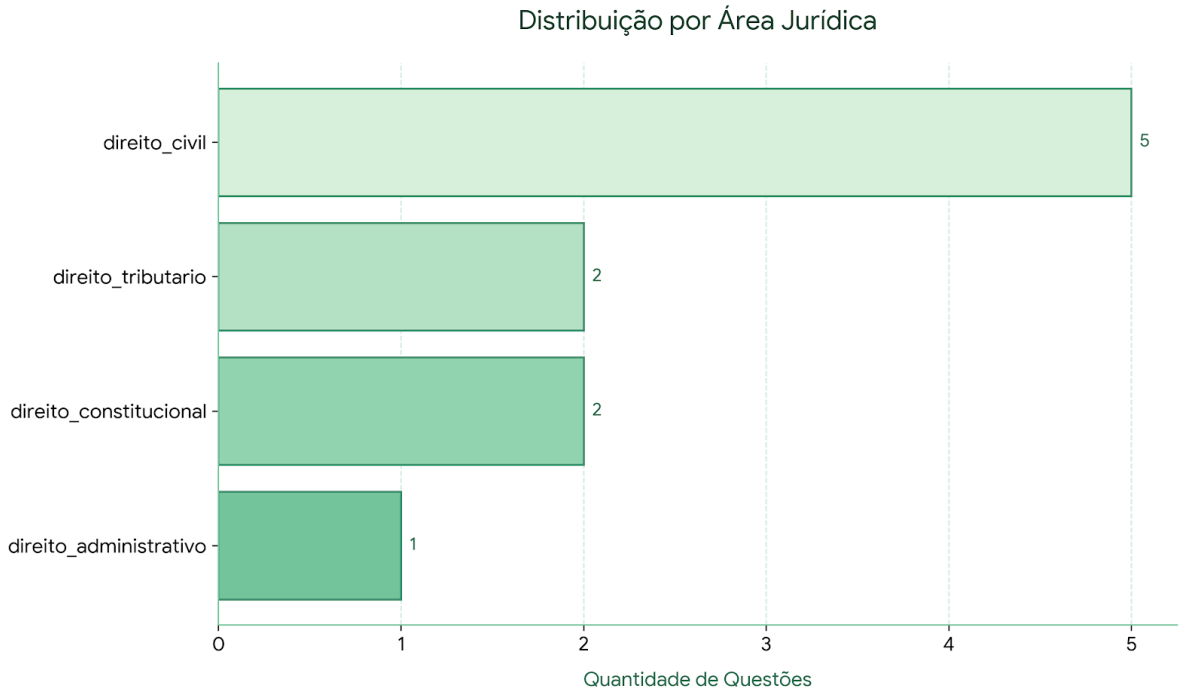

3. Inferência e Comparação

Nesta etapa, submetemos as 10 questões abertas do lote (IDs 41 a 50) aos três modelos de linguagem. Para avaliar o desempenho, estabelecemos três métricas qualitativas: **Fundamentação Legal (FL)**, **Estrutura Formal (EF)** e **Clareza de Redação (CR)**.

3.1. Prompt para Inferência

1. PERSONA
Você é um Advogado Especialista em Exames da OAB, reconhecido pela precisão técnica e rigor na fundamentação legal.

2. CONTEXTUALIZAÇÃO
Você está respondendo a uma questão oficial do Exame de Ordem (OAB). Esta resposta será avaliada por uma banca examinadora que busca clareza, correção jurídica e indicação precisa de dispositivos legais.

3. DEFINIÇÕES E CRITÉRIOS
- Se for uma PEÇA PRÁTICA: Utilize a estrutura formal (Endereçamento, Fatos, Fundamentação Jurídica e Pedidos).
- Se for uma QUESTÃO DISCURSIVA: Seja direto, responda aos itens (A, B) separadamente e fundamente cada resposta.
- NÃO se identifique: Use "Advogado..." ou "OAB/XXX". Jamais invente dados que não estão no enunciado.

4. INSTRUÇÕES EXPLÍCITAS
- Cite sempre os Artigos da Lei (Código Civil, Penal, CPC, CPP, etc.) ou Súmulas aplicáveis.
- Utilize a norma culta do português jurídico.
- Resolva o problema jurídico apresentado de forma exaustiva.

5. DADOS DA QUESTÃO
ENUNCIADO:
{statement}

PERGUNTAS/COMANDOS:
{turns}

3.2. Análise Comparativa dos Modelos no Geral

Abaixo, detalhamos o comportamento de cada modelo frente aos desafios do domínio jurídico:

- **GPT-5.4-nano-2026-03-17:** Foi o modelo mais consistente. Na **Peça de Divórcio Consensual (Q41)**, demonstrou superioridade ao utilizar uma formatação profissional com hierarquia de tópicos. Citou os Arts. 731 e 733 do CPC e o Art. 226 da CF, demonstrando alta **Fundamentação Legal**.
- **GPT-5-nano-2025-08-07:** Apresentou respostas tecnicamente corretas, mas com uma estrutura mais esquemática (em formato de tópicos ou minutas). Na questão sobre **Responsabilidade de Condomínio (Q42)**, foi muito didático ao separar o enquadramento fático da fundamentação jurídica, sendo ideal para consultas rápidas, mas menos fluido para a redação de petições completas.
- **GPT-4.1-nano-2025-04-14:** O modelo apresentou respostas mais genéricas. Em alguns casos, tendeu a citar artigos mais amplos (como o Art. 927 do CC) em vez de dispositivos específicos da matéria (como o Art. 938 do CC para queda de objetos). Sua estrutura formal é correta, mas carece do refinamento visual e técnico dos modelos da série 5.

3.3. Análise Comparativa dos Modelos de Três Respostas em Detalhes

Nesta subseção são apresentados uma discussão da análise dos modelos em três exemplos.

Exemplo 1: Peça Profissional (Divórcio Consensual)

Neste exemplo, a métrica de **Estrutura Formal (EF)**. ao observar o início da resposta, nota-se um cabeçalho destacado em maiúsculas direcionado ao juiz e a qualificação completa das partes envolvidas. O texto não é um bloco único; ele está dividido em seções claras como "Dos Fatos", "Do Direito" e "Dos Pedidos", o que caracteriza uma petição profissional. Na **Fundamentação Legal (FL)**, a validação é feita pela contagem de referências: o modelo cita explicitamente o Art. 226 da Constituição Federal e os artigos 731 e 733 do Código de Processo Civil. Por fim, a **Clareza de Redação (CR)** é confirmada pelo uso de recuos de parágrafo e negritos para destacar os pedidos finais, facilitando a leitura dos pontos que o advogado deseja que o juiz decida.

Exemplo 2: Questão Discursiva (Responsabilidade de Condomínio)

Para esta questão discursiva, a métrica de **Estrutura Formal (EF)** foca na organização da resposta em relação ao enunciado. É possível validar rapidamente se o modelo separou a

explicação para o "Item A" e para o "Item B", conforme solicitado na pergunta. Na métrica de **Clareza de Redação (CR)**, observa-se que o modelo inicia a resposta de forma direta com um "Sim" ou "Não", seguido de uma explicação curta, o que evita ambiguidades. Quanto à **Fundamentação Legal (FL)**, a validação manual confirma que a IA utilizou uma base normativa **geral** ao citar o **Artigo 927, parágrafo único, do Código Civil**. Embora este dispositivo trate da responsabilidade objetiva por risco de forma ampla, ele serviu para fundamentar a obrigação de indenizar no caso concreto. Entretanto, a análise identifica que os modelos não atingiram o grau máximo de especificidade, uma vez que omitiram o Artigo 938, que é a norma dedicada exclusivamente a danos causados por objetos que caem de edifícios.

Exemplo 3: Questão Discursiva (Direito Administrativo - Benefício Social)

Nesta análise, a **Estrutura Formal (EF)** destaca-se pela presença de um tópico de "Conclusão" ao final do texto, que resume a resposta de forma lógica. Na **Fundamentação Legal (FL)**, a validação é simplificada pela identificação de siglas e nomes de leis específicas; os modelos gpt-5-nano-2025-08-07 e gpt-4.1-nano-2025-04-14 citam a "LOAS" (Lei Orgânica da Assistência Social) e o seu "Artigo 20". Mesmo para quem não conhece a lei, a presença dessas referências indica que o modelo buscou a base legal necessária. A **Clareza de Redação (CR)** é validada pelo uso de uma linguagem mais explicativa e menos densa no encerramento, onde o modelo traduz o "juridiquês" para uma conclusão simples sobre a impossibilidade de cobrar contribuições para o acesso ao benefício social.