Relatório

1. Objetivo

Este relatório tem como objetivo apresentar uma análise comparativa entre três modelos de IA: GPT-5.3, Claude Sonnet 4.6 e o Gemini modelo rápido.

A comparação foi realizada a partir das respostas geradas pelos modelos para as questões 1 a 10 das abertas e 1 A 105 das fechadas dos datasets fornecidos, considerando quatro dimensões principais para as questões abertas: classificação de nível da questão, aderência da área/categoria ao dataset, similaridade entre as respostas textuais e completude da base legal utilizada. Considerando para as questões fechadas: acurácia, taxa de erro, e Exact Match (EM).

2. Base de análise

A análise foi construída a partir de um dataset contendo as questões, a peça prática/base do problema e a categoria jurídica.

> Para acessar o dataset - questões abertas, clique em: https://raw.githubusercontent.com/maritaca-ai/oab-bench/main/data/oab_bench/question.jsonl
>
> Para acessar o dataset - questões fechadas, clique em:
>
> https://huggingface.co/datasets/eduagarcia/oab_exams

Para utilizar as questões do dataset, precisei realizar a seleção das questões, limpei os dados desnecessários e apliquei-as IAs.

3. Metodologia adotada

A análise foi feita por inferência comparativa, já que não há gabarito oficial para validação das respostas nas questões abertas, e nas questões fechadas foi feita a comparação, questão por questão referente ao campo “answerkey”.

Para que as três IAs selecionadas trouxessem um resultado para cada questão foi preciso criar um prompt onde elas pudessem trazer o mesmo modelo de resposta.

3.1 Prompt Usado

- **Questões abertas**

Você é um especialista em Direito Brasileiro e exames da OAB.

Sua tarefa é analisar peças prático-profissionais e questões discursivas, fornecendo respostas fundamentadas e uma avaliação técnica de dificuldade e especialidade.

REGRAS DE SAÍDA:

1. A resposta deve ser EXCLUSIVAMENTE em formato JSON.

2. Não adicione texto explicativo antes ou depois do JSON.

3. Mantenha a hierarquia: Peça Profissional -> Questões Discursivas.

TAXONOMIA DE DIFICULDADE:

- Nível 1 (Estagiário): Aplicação direta da lei (literalidade).

- Nível 2 (Analista): Conhecimento de ritos processuais, prazos ou leis específicas.

- Nível 3 (Juiz de Direito): Interpretação de casos práticos e subsunção do fato à norma.

- Nível 4 (Ministro STF/STJ): Questões complexas, controle de constitucionalidade, súmulas vinculantes ou conflitos de leis.

ESTRUTURA DO JSON ESPERADA:

{ "IDENTIFICADOR_DA_PECA": { "PRACTICAL-PROFESSIONAL_PIECE_ANALYSIS": {

"title": "Título da Peça",

"piece_text": "Texto original ou resumo",

"model_answer": "Resolução jurídica fundamentada",

"difficulty_level": [1-4],

"classification": "Nível [Nome]",

"justification": "Por que este nível?",

"area_of_expertise": "Ex: Direito Civil",

"main_legal_reference": "Artigos principais" },

"QUESTION_N": {

"question": "Texto da questão",

"model_answer": "Resposta com fundamentação legal",

"difficulty_level": [1-4],

"classification": "Nível [Nome]",

"justification": "Breve justificativa técnica",

"area_of_expertise": "Subárea específica",

"main_legal_reference": "Artigos principais" } } }

TAREFA: Analise os textos fornecidos a seguir e preencha a estrutura acima. [INSIRA O TEXTO DA PEÇA E DAS QUESTÕES AQUI]

- **Questões fechadas**

Você é um especialista em Direito Brasileiro e exames da OAB.

Sua tarefa é analisar peças prático-profissionais e questões discursivas, fornecendo respostas fundamentadas e uma avaliação técnica de dificuldade e especialidade.

REGRAS DE SAÍDA: verifique o PDF, lei as colunas, verifique as questões na coluna "question", as alternativas na coluna "choices" e responda, no seguinte formato: Index 0: A

Após executar o prompt nas três IAs, salvamos os arquivos em formato json.

3.2 Classificação de nível

Foi comparado o campo “classification” dos três modelos, observando se houve consenso ou divergência na atribuição de dificuldade.

Os níveis considerados foram:

- Nível 1: Estagiário
- Nível 2: Analista
- Nível 3: Juiz de Direito
- Nível 4: Ministro STF/STJ

3.3 Aderência à categoria do dataset

Foi comparado o campo “area_of_expertise” de cada modelo com o campo “category” do dataset.

Aqui o critério usado foi de aderência temática ao macrotema principal da questão.

3.4 Similaridade textual das respostas

Foi calculada a similaridade média entre os pares de modelos com base na redação do campo “model_answer”.

Essa similaridade não mede correção jurídica. Ela mede apenas o quanto os textos se parecem entre si.

3.5 Completude da base legal

Foi construído um score aproximado de completude com base em elementos como:

- Quantidade de artigos citados;
- Presença de parágrafos e incisos;
- Menção a leis, Constituição, súmulas, precedentes ou regimentos;
- Densidade de referência normativa.

Esse indicador não mede se a base legal está certa ou errada. Ele mede o quanto a fundamentação aparenta estar desenvolvida.

3.6 Índice de divergência por questão

Foi criado um índice de divergência combinando três fatores:

- Divergência na classificação de nível;
- Divergência de categoria em relação ao dataset;
- Baixa similaridade textual entre as respostas.

Esse índice serve para mostrar em quais questões os modelos mais se afastaram entre si.

3.7 Acurácia

Acurácia = número de acertos / total de questões

3.8 Taxa de Erro

Taxa de Erro = número de erros / total de questões

3.9 Exact Match (EM)

O Exact Match mede a proporção de respostas que coincidem exatamente com o gabarito.

4. Resultados principais

- **Questões abertas**

4.1 Distribuição dos níveis por modelo

O primeiro gráfico mostra quantas vezes cada modelo classificou as questões em cada nível.

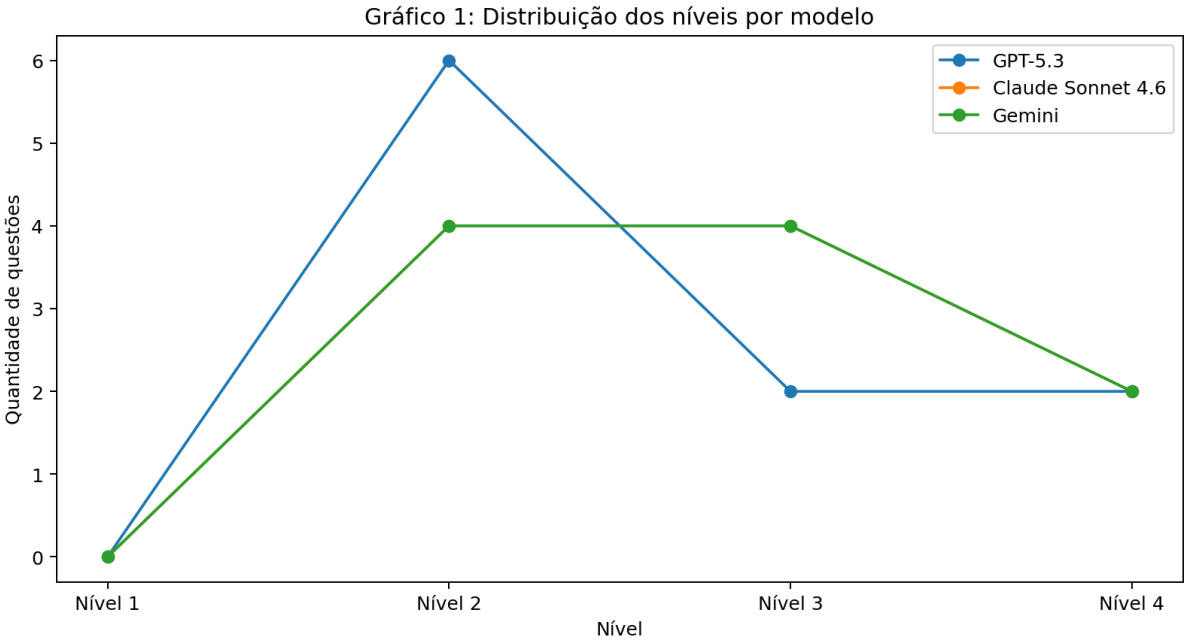

O comportamento dos modelos sugere perfis diferentes de avaliação:

- **GPT-5.3** apresentou um perfil mais conservador, concentrando mais respostas nos níveis intermediários.
- **Claude Sonnet 4.6** demonstrou tendência a elevar algumas questões para um grau maior de complexidade.
- **Gemini** ficou em posição intermediária, mas também apresentou elevação em algumas questões específicas.

Esse gráfico é importante porque mostra que os modelos não apenas respondem de forma diferente, mas também "enxergam" a complexidade da questão de forma distinta. Isso pode impactar diretamente a forma como justificam a resposta e a densidade da fundamentação.

4.2 Aderência à categoria do dataset

O segundo gráfico compara o número de questões em que a área atribuída pelo modelo foi aderente à categoria do dataset.

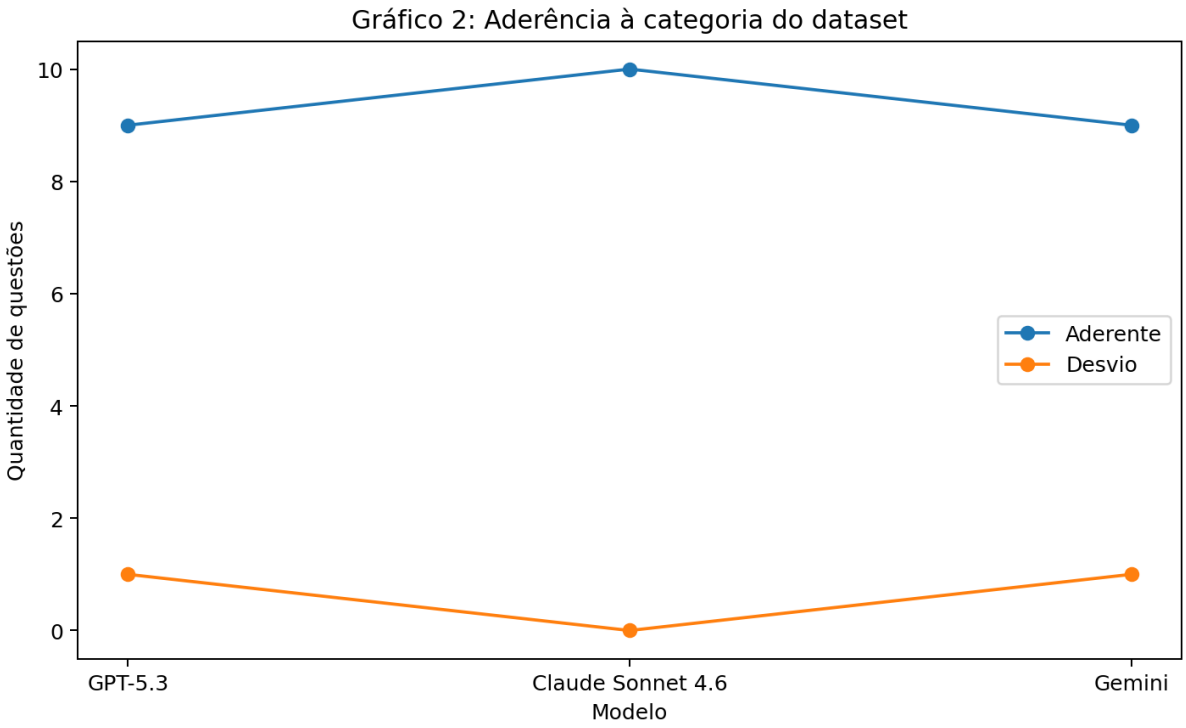

Resultado observado

- Claude Sonnet 4.6: **10 aderências em 10**
- GPT-5.3: **9 aderências em 10**
- Gemini: **9 aderências em 10**

Claude foi o modelo mais consistente nesse ponto. Isso significa que ele conseguiu manter o enquadramento das questões mais próximo da classificação original do dataset.

GPT-5.3 e Gemini também tiveram bom desempenho, mas em um caso cada um houve deslocamento de categoria.

Esse gráfico é especialmente relevante porque a categoria do dataset é a referência mais objetiva disponível. Assim, nesse critério, Claude mostrou maior estabilidade.

4.3 Similaridade média entre pares de modelos

O terceiro gráfico apresenta a similaridade média das respostas entre cada par de modelos.

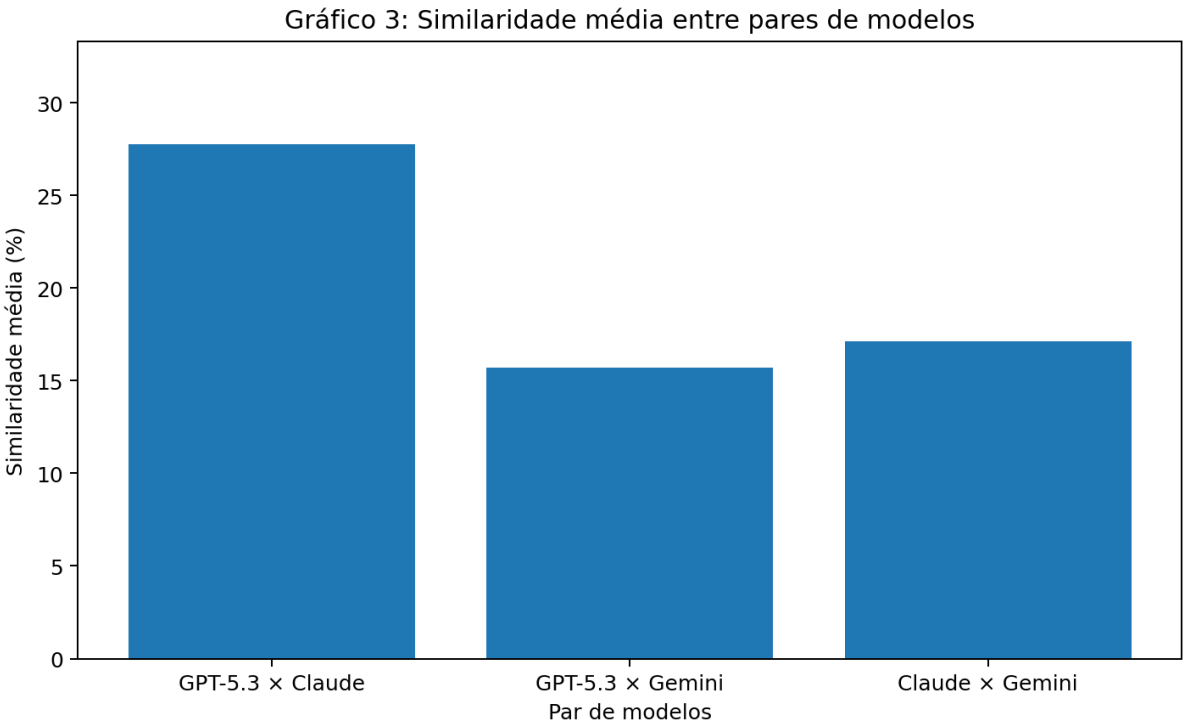

Médias observadas

- GPT-5.3 × Claude: **27,78%**
- GPT-5.3 × Gemini: **15,69%**
- Claude × Gemini: **17,15%**

As respostas não são textualmente parecidas em alto grau. A maior proximidade ocorreu entre GPT-5.3 e Claude, mas ainda assim com percentual relativamente baixo.

Isso mostra que, mesmo quando os modelos chegam a conclusões semelhantes, a formulação textual muda bastante.

Esse resultado reforça que os modelos não podem ser tratados como meras variações estilísticas entre si. Há diferenças reais de construção argumentativa, organização da resposta e seleção de fundamentos.

4.4 Divergência por questão

O quarto gráfico apresenta um índice de divergência por questão, combinando diferenças de nível, categoria e redação.

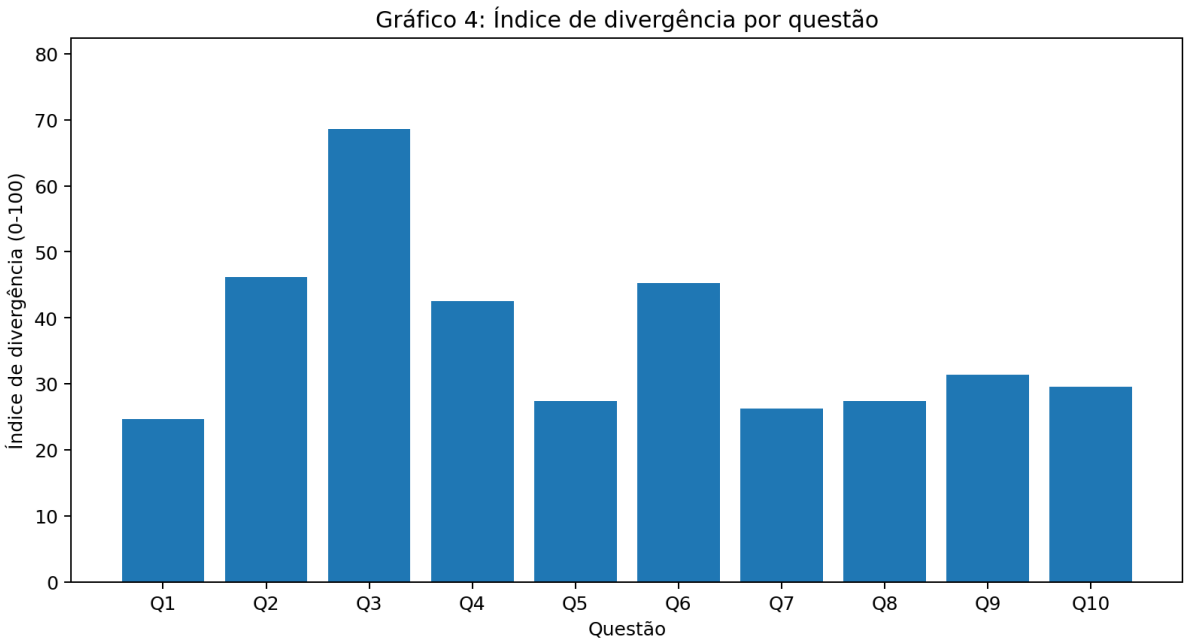

Esse é um dos gráficos mais importantes do conjunto, porque mostra onde os modelos mais se afastaram.

De forma geral:

- As questões com menor índice de divergência indicam maior consenso estrutural entre os modelos;
- As questões com maior índice de divergência indicam maior dispersão interpretativa.

As questões com maior divergência merecem atenção especial no relatório final, porque são justamente aquelas em que os modelos:

- classificaram a dificuldade de formas distintas;
- adotaram enquadramentos jurídicos diferentes;
- ou produziram respostas menos parecidas entre si.

Na prática, esse gráfico ajuda a selecionar as questões mais sensíveis para discussão qualitativa aprofundada.

4.5 Completude da base legal por modelo

O quinto gráfico compara o score médio de completude da base legal usada por cada modelo.

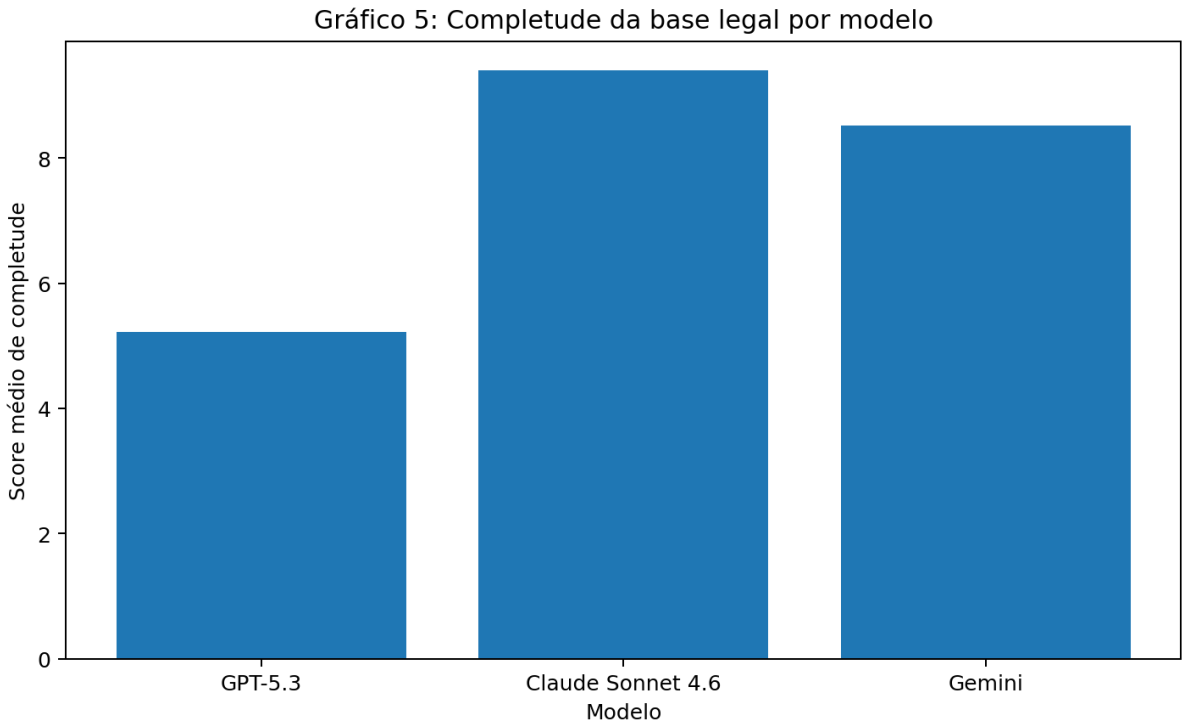

Médias observadas

- GPT-5.3: **5,225**
- Claude Sonnet 4.6: **9,400**
- Gemini: **8,525**

Claude foi o modelo com maior densidade de fundamentação normativa, seguido por Gemini. GPT-5.3 apresentou respostas com base legal mais enxuta.

Esse resultado indica que Claude e Gemini tendem a citar mais dispositivos, leis e referências complementares. GPT-5.3, por outro lado, mostra perfil mais econômico.

Isso não permite concluir, sozinho, qual modelo "acerta mais", mas permite afirmar qual modelo entrega fundamentação mais rica em termos quantitativos.

- **Questões Fechadas**

Modelo	**Acertos**	**Erros**	**Acurácia**	**Taxa de Erro**	**Exact Match (EM)**
Claude Sonnet 4.6	83	23	78,30%	21,70%	78,30%
ChatGPT 5.3	69	37	65,09%	34,91%	65,09%
Gemini	45	61	42,45%	57,55%	42,45%

O Claude Sonnet 4.6 obteve o melhor desempenho entre os três modelos nas questões fechadas, com 83 acertos em 106 questões, alcançando 78,30% de acurácia. Isso significa que, em quase quatro quintos da prova, sua resposta coincidiu exatamente com o gabarito.

O ChatGPT 5.3 apresentou desempenho intermediário, com 69 acertos e 65,09% de acurácia. Embora tenha ficado abaixo do Claude, ainda se manteve acima da marca de 60%, indicando consistência razoável em perguntas objetivas.

O Gemini, por sua vez, apresentou o menor desempenho relativo, com 45 acertos e 42,45% de acurácia, o que indica que errou mais da metade das questões. Sua taxa de erro de 57,55% foi a mais alta entre os modelos comparados.

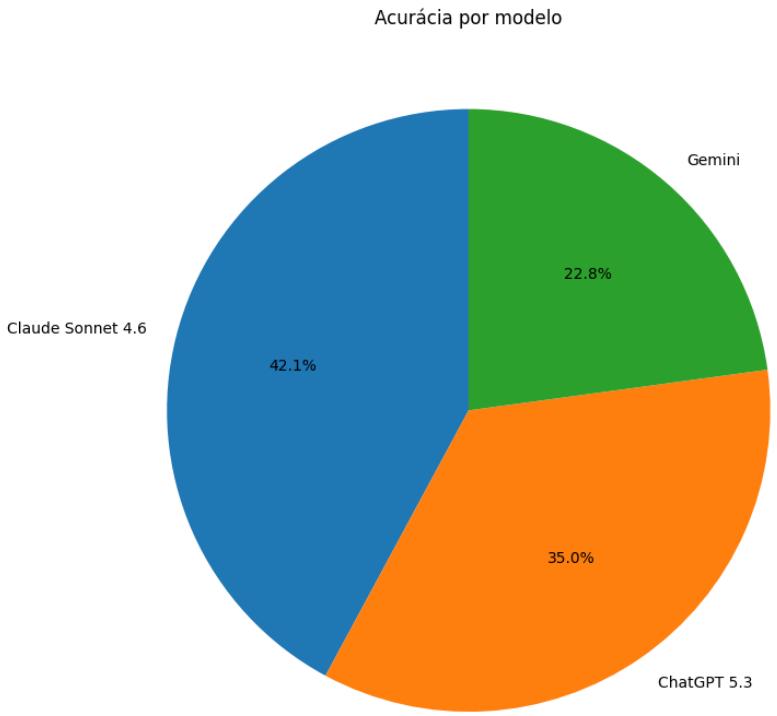

5. Conclusões

A análise conjunta mostra que, nas questões abertas, o Claude Sonnet 4.6 foi o modelo mais consistente, enquanto o GPT-5.3 se destacou pela objetividade e concisão, e o Gemini apresentou respostas mais variáveis. Já nas questões fechadas, o Claude Sonnet 4.6 também obteve o melhor desempenho, com maior acurácia e Exact Match e menor taxa de erro, seguido pelo ChatGPT 5.3, enquanto o Gemini ficou abaixo dos demais. Em conjunto, os resultados indicam que o Claude foi o modelo mais consistente no cenário analisado, reunindo melhor desempenho qualitativo nas respostas abertas e melhor desempenho quantitativo nas questões objetivas.