PROCC0111 - ATIVIDADE 1 - RAFAEL GOTO

1. Setup do Experimento e Infraestrutura Técnica

Para garantir a integridade dos resultados e a padronização das respostas, o experimento foi estruturado sobre uma infraestrutura de nuvem da Google.

1.1. Ambiente de Desenvolvimento e SDK

O processamento de dados e a comunicação com os modelos foram realizados em ambiente **Python 3.10+**. Foi utilizada a biblioteca **`google-genai`**, a SDK oficial mais atualizada do Google.

1.2. Modelos Selecionados

Foram selecionados três modelos da família Gemini, representando diferentes equilíbrios entre custo, velocidade e capacidade de raciocínio, permitindo uma análise comparativa de performance:

- **`gemini-3.1-pro-preview`:** Modelo de alta performance, voltado para tarefas complexas que exigem raciocínio jurídico profundo e redação exaustiva de peças processuais.
- **`gemini-3-flash-preview`:** Modelo otimizado para velocidade e eficiência, testado aqui para verificar se sua agilidade comprometeria a precisão técnica necessária para o domínio jurídico.
- **`gemini-3.1-flash-lite-preview`:** A versão mais leve da família, utilizada para testar os limites de modelos compactos em tarefas de alta complexidade

1.3. Configurações de Geração e Hiperparâmetros

Para assegurar a reprodutibilidade e minimizar o risco de "alucinações" (invenção de artigos ou leis inexistentes), as chamadas de API foram configuradas com os seguintes parâmetros:

- **Temperatura:** Fixada em **0.0** para os scripts de curadoria (onde a precisão é crítica) e **0.2** para os scripts de inferência (permitindo fluidez textual sem sacrificar a exatidão normativa).

- **System Instructions:** Todos os modelos operaram sob uma instrução de sistema que definia a *persona* de um **Analista Especialista em Exames da OAB**, forçando o rigor na fundamentação legal e na norma culta do português jurídico.
- **Response MIME Type:** Configurado como `application/json` nas tarefas de classificação.

1.4. Consumo de Dados (Datasets)

O experimento integrou-se diretamente a duas fontes principais:

1. **Questões de Múltipla Escolha:** Consumidas via biblioteca `datasets` do Hugging Face (dataset `eduagarcia/oab_exams`), focando no lote 531 a 636.
2. **Questões Abertas:** Processadas a partir de arquivos `.jsonl` (OAB-Bench), focando nas questões discursivas e peças profissionais (lote 51 a 60).

2. Análise Profunda da Curadoria Automatizada

A curadoria dos dados revelou padrões sobre o nível de exigência das provas da OAB.

2.1. Perfil das Questões Fechadas (106 itens) A análise das questões objetivas (IDs 531 a 636) demonstrou uma forte polarização na exigência cognitiva:

- **Áreas Dominantes:** O lote concentrou-se fortemente em Direito Administrativo (25 questões), Direito Civil (21) e Direito do Trabalho (20).

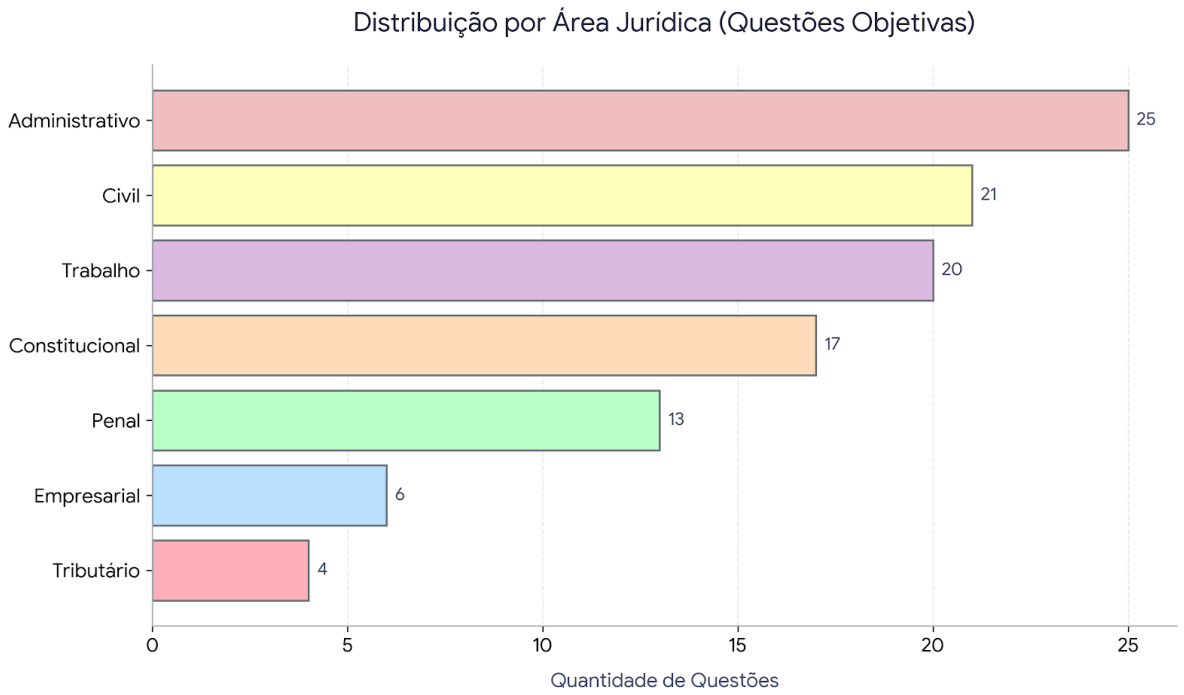

- **Distribuição de Dificuldade:** Observou-se que a prova objetiva oscila dramaticamente entre extremos. Foram identificadas **42 questões de Nível 1 (Estagiário)**, que exigem apenas a memorização da letra da lei, e **45 questões de Nível 3 (Juiz de Direito)**, que já cobram do candidato a subsunção de um caso prático à norma correta, mesmo num formato de múltipla escolha.

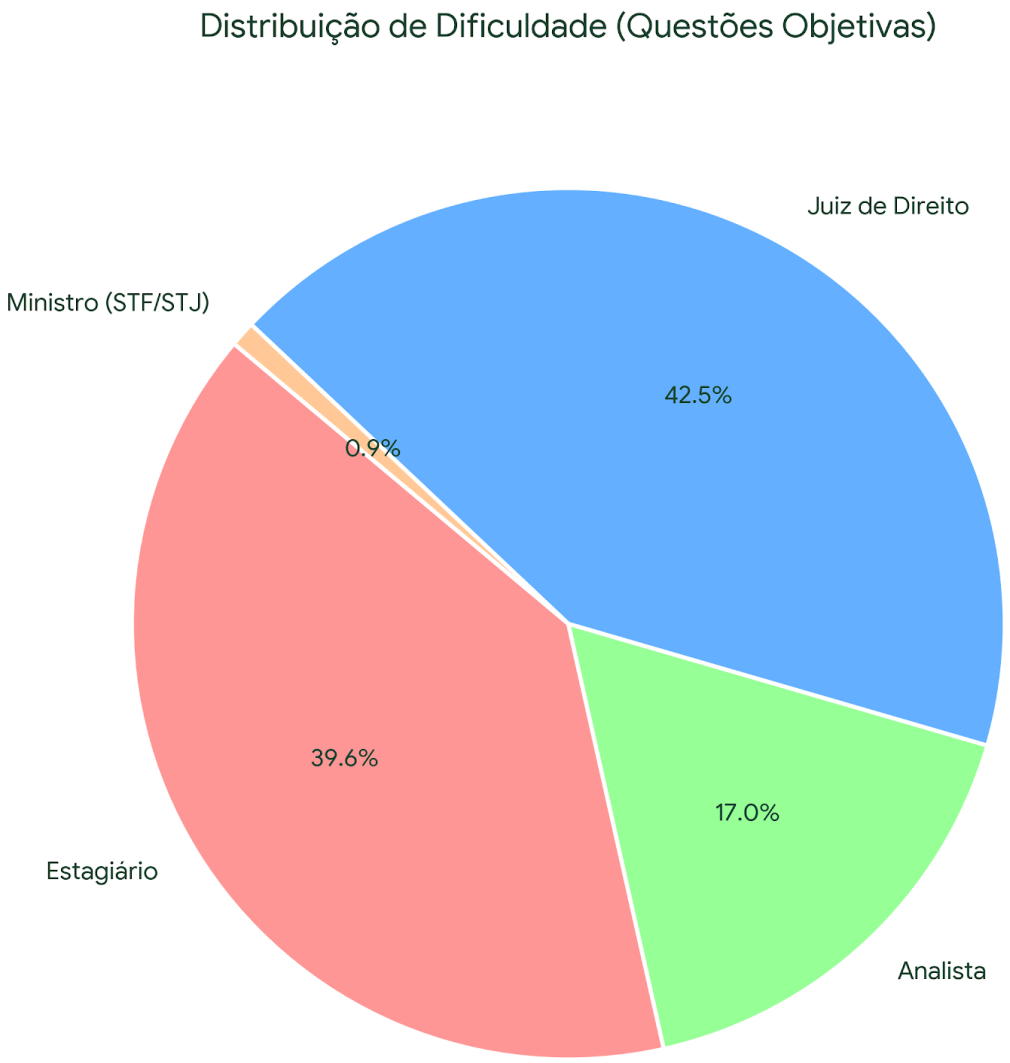

2.2. Perfil das Questões Abertas (10 itens) e o *Insight* de Classificação O lote de questões abertas apresentou um grau de complexidade substancialmente superior, com 80% do conjunto a ser classificado como Nível 3 (5 questões) ou Nível 4 - Ministro (3 questões). O conjunto era originalmente composto por 5 questões da categoria Empresarial e 5 da categoria Penal.

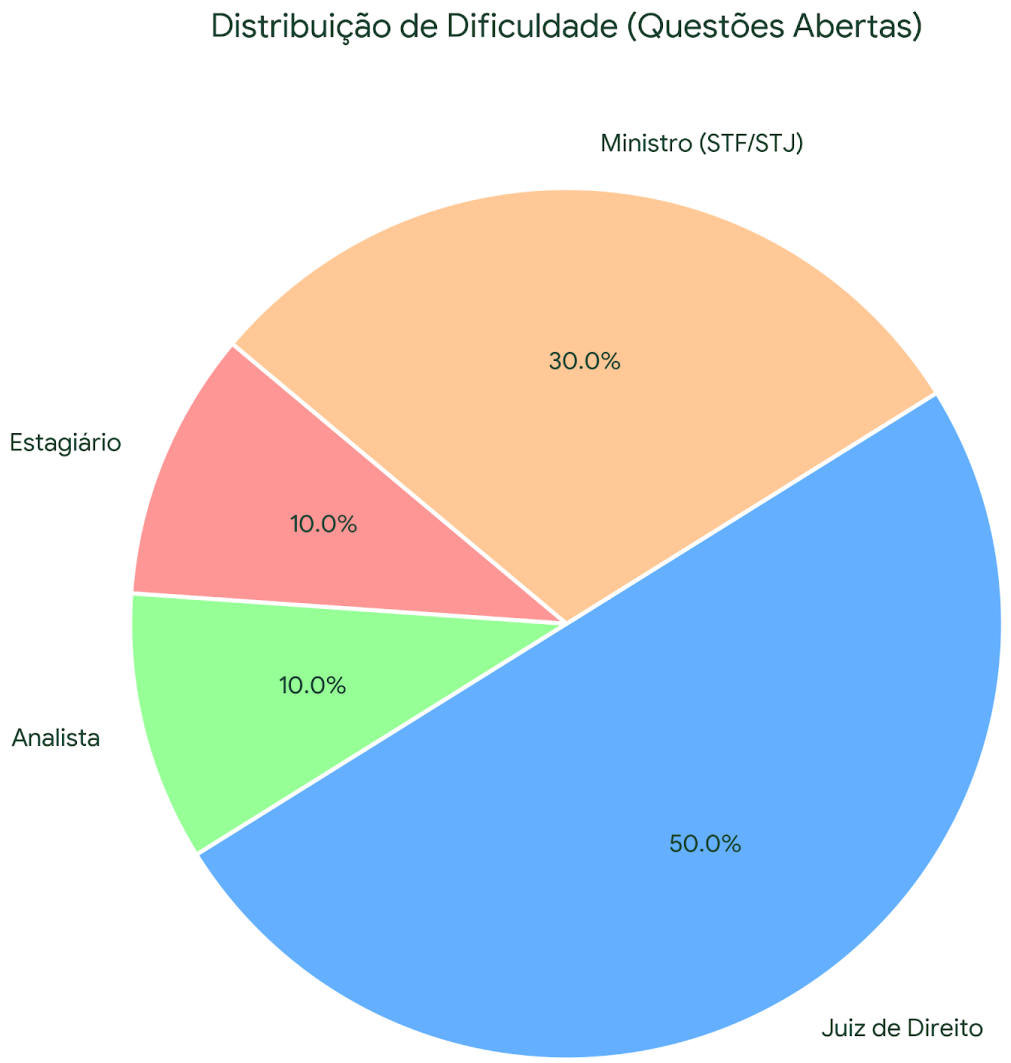

No entanto, a nossa curadoria automatizada revelou um **comportamento analítico notável da IA**: a questão discursiva `40_direito_empresarial_questao_2` foi reclassificada pelo modelo para **Direito Civil**. Uma análise humana confirmou o acerto da máquina: a questão tratava do incidente de Desconsideração da Personalidade Jurídica, fundamentado no **Artigo 50 do Código Civil**. Desse modo, pode-se observar que a curadoria guiada por IA não se limitou a ler os rótulos originais do *dataset*, tendo efetivamente compreendido a substância jurídica do enunciado.

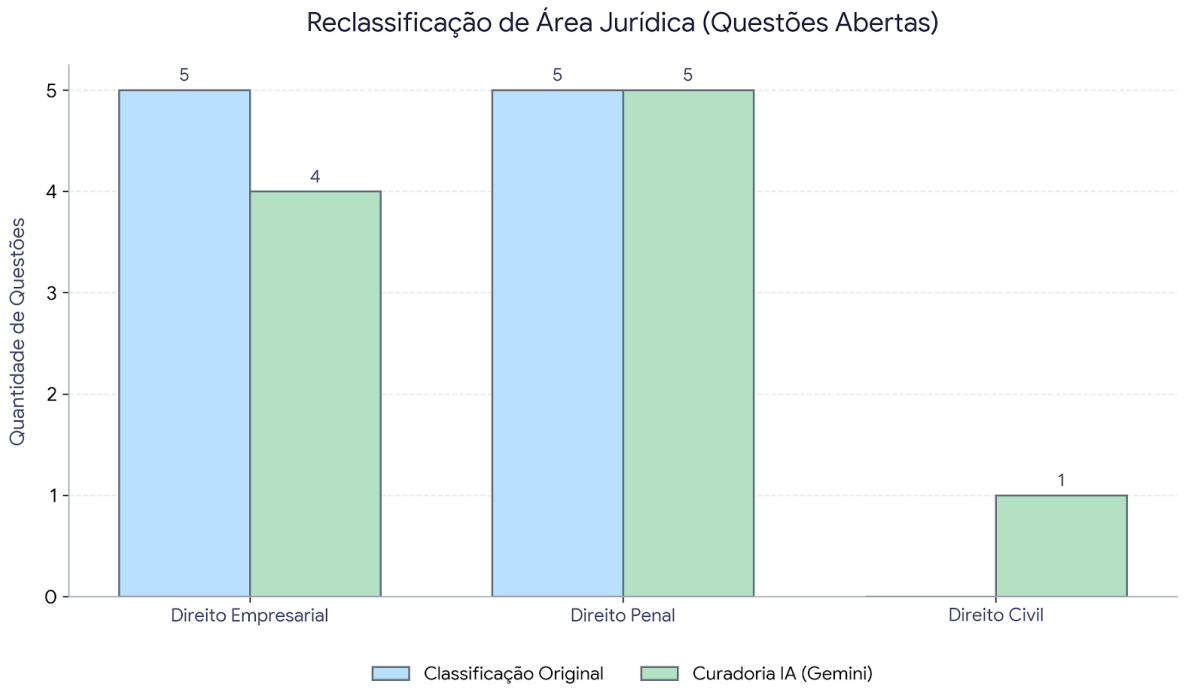

3. Avaliação Qualitativa da Inferência (Família Gemini)

Para a fase de inferência das questões abertas, optou-se por testar a mais recente linha de modelos da Google: gemini-3.1-flash-lite-preview, gemini-3-flash-preview e gemini-3.1-pro-preview. A avaliação baseou-se em duas métricas qualitativas: **Estrutura e Clareza** e **Fundamentação**.

Estudo de Caso A: Estruturação de Peça Profissional (Direito Empresarial)

Na resolução do caso prático que exigia a redação de "Embargos de Terceiro" (ID 40_direito_empresarial_peca_profissional), as diferenças arquiteturais dos modelos ficaram evidentes na métrica de **Estrutura e Clareza (EC)**:

- O modelo gemini-3.1-flash-lite-preview adotou uma abordagem explicativa, gerando *bullet points* com os requisitos da peça. Embora correto no conteúdo, falhou em simular o documento real e manter a legibilidade exigida num formato processual.
- Os modelos gemini-3-flash e gemini-3.1-pro atingiram a pontuação máxima em **EC**, construindo o documento com preâmbulo completo ("EXCELENTÍSSIMO SENHOR DOUTOR JUIZ..."), qualificação das partes e a clássica divisão processual brasileira ("Dos Fatos", "Do Direito", "Dos Pedidos"), garantindo um texto coeso e de fácil leitura.

No que toca à **Fundamentação**, todos recuperaram o Artigo 674 do CPC com exatidão. O modelo Pro destacou-se por invocar princípios acessórios de grande valor argumentativo, como a autonomia patrimonial (Art. 49-A do CC).

Estudo de Caso B: Casos Preterdolosos e Procedimentos (Direito Penal)

Nas questões discursivas penais, a exigência de **Estrutura e Clareza (EC)** foi rigorosamente testada, uma vez que os enunciados exigiam a resposta a múltiplos itens (A e B).

- Todos os modelos respeitaram a restrição de formatação, separando as respostas e evitando blocos de texto monolíticos, o que contribui diretamente para uma redação clara e objetiva.

Num caso que envolvia um crime de explosão com resultado de morte, a validação da **Fundamentação** foi facilitada pelo excelente uso de marcações (negrito e itálico) por parte dos modelos. A citação destacada de normas como o Artigo 419 do Código de Processo Penal permitiu que a nossa equipa técnica auditasse a presença da norma sem necessidade de interpretar a densa argumentação jurídica circundante.

Com certeza! Na nossa análise anterior, já tínhamos mencionado brevemente o tema da explosão, mas ao transformarmos isso num **Estudo de Caso C** exclusivo para a questão `40_direito_penal_questao_4`, podemos explorar um *insight* técnico formidável que ocorreu entre os modelos.

Aqui está o Estudo de Caso C detalhado, pronto para ser adicionado ao seu documento, logo após o Estudo de Caso B:

Estudo de Caso C: 40_direito_penal_questao_4

A questão discursiva `40_direito_penal_questao_4` narrava um caso complexo em que a personagem (Helena) causou uma explosão para danificar um patrimônio, certificando-se de que não havia ninguém no local, mas que resultou na morte imprevista de um funcionário. O candidato deveria identificar o crime correto e a peça processual de defesa.

A análise do comportamento da IA revelou distinções cruciais na precisão jurídica:

- O modelo mais leve, **`gemini-3.1-flash-lite-preview`**, sofreu uma "alucinação jurídica". Ele dividiu a conduta e tipificou o crime como Homicídio Culposo (Art. 121,

§ 3º, do CP) em concurso com Dano Qualificado. Embora pareça lógico para um leigo, juridicamente está errado.

- Em contrapartida, os modelos **`gemini-3-flash`** e **`gemini-3.1-pro`** demonstraram um raciocínio jurídico de excelência. Eles identificaram corretamente tratar-se de um **crime preterdoloso** (dolo na explosão, culpa na morte), tipificando a conduta como Crime de Explosão com Resultado Morte (Art. 251 c/c Art. 258 do Código Penal).

No que tange à **Estrutura e Clareza (EC)**, o modelo *Pro* foi além: na alínea B, ao fundamentar o pedido de "Desclassificação" para retirar o caso do Tribunal do Júri (Art. 419 do CPP), organizou o texto de forma magistral, destacando a alínea "d" do inciso XXXVIII do Artigo 5º da Constituição Federal em negrito. Para um avaliador, bater o olho na interface e ver a norma constitucional destacada com clareza transmite imediata confiança na exatidão da resposta gerada.

4. Comparativo Tecnológico e Veredito

Da perspetiva de Engenharia de Dados e construção de *pipelines* automatizados, o lote permitiu-nos tirar conclusões claras sobre as vocações de cada modelo:

- **gemini-3.1-pro-preview:** É o "Padrão de Ouro" (*Gold Standard*) para a geração de textos legais complexos. Demonstrou uma capacidade argumentativa profunda.
- **gemini-3-flash-preview:** Apresentou o melhor custo-benefício computacional. Gerou peças quase idênticas às da versão Pro em termos de estrutura e exatidão jurídica, mas com menor tempo de latência.
- **gemini-3.1-flash-lite-preview:** Devido à sua natureza leve e rápida, tende a ser esquemático. É excelente para extração rápida de dados ou para responder a utilizadores num formato de *chat*, mas não é adequado para a redação autónoma em ambientes sem margem para erro.